

黄鑫

AI 算法工程师求职 - 2028 届硕士生

专注多模态视频理解与大模型应用，具备从数据构建、模型训练、流式推理到系统部署的完整工程经验。当前研究方向为流式长视频内容理解、视觉语言模型与 AI Agent。

电话 18767752677
邮箱 1366887360@qq.com
微信 hx1366887360
GitHub github.com/H-X1n
个人网页 h-x1n.github.io/Huangxin.github.io
所在地 上海浦东

技术能力

深度学习	PyTorch, Transformers, PaddlePaddle, PaddleOCR	大模型	Qwen2.5-VL, LoRA/QLoRA, Mamba, RL, DPO, PPO, Distributed Training
计算机视觉	YOLO 系列, InsightFace, OpenCV, 多模态 VLM	RAG 检索	BGE-M3, BGE-Reranker-v2, 向量检索, 语义重排
工程能力	Python, Git, Linux, JSON Output, Hugging Face 部署	数据工程	大规模数据集构建, 多模态数据清洗, 流式视频 QA 标注

实习经历

咪咕视讯科技有限公司 - AI 算法工程师实习生 2026.01 - 2026.07

围绕足球直播场景，参与多模态理解、RAG 解说、目标检测与 OCR 自动识别等业务项目。

- SoccerStreamer**: 设计流式因果视频语言模型系统，支持用户对正在直播的足球比赛进行自然语言实时问答，模型仅基于已播出画面作答。
- 以 **Qwen2.5-VL-7B** 为基座，自研基于 Mamba + SwiGLU 的时序投影器，在视觉 token 进入 LLM 前显式建模跨帧时序关系。
- 采用 Spatial Pool 4x4 + Temporal Sampling，实现约 **32x token 压缩**，降低流式推理显存与延迟开销。
- 构建覆盖 **422 场** 完整比赛的流式足球 QA 数据集，包含 **12 万+** QA 模板与 **3.2 万+** 固定 QA，并按 short/mid/long 记忆延迟分层。
- 制定四阶段课程训练策略，冻结视觉编码器，仅训练投影器与 LLM LoRA，并完成 **8xA100** 分布式训练。
- 参与世界杯直播流 AI 解说员项目，构建百万字级多风格足球解说语料库，接入 BGE-M3 + BGE-Reranker-v2-m3 两阶段 RAG 检索增强，并基于偏好样本构建 DPO 数据集，增强模型专业、激情、幽默等风格化解说能力。
- 参与球员目标检测与足球比赛 UI 自动识别，基于 YOLO、OpenCV、PaddleOCR 完成球员检测、比分识别和赛事基础数据自动采集。

Qwen2.5-VL-7B Mamba LoRA DPO FSDP RAG YOLO PaddleOCR

核心项目

SoccerStreamer: 足球直播场景下的 ChatModel 实习核心项目

- 面向足球直播实时问答，构建“已播出内容可见、未来内容不可见”的因果推理框架，覆盖事件计数、首次事件时间、阶段性总结等任务。
- 提出基于 Mamba 的时序投影器替换原生视觉投影器，在保持压缩效率的同时增强跨帧关系建模。
- 关键指标: 32x token 压缩、422 场完整比赛、12 万+ QA 模板、8xA100 训练。

基于 Transformer 架构的中英机器翻译系统 个人项目

- 参照 Attention Is All You Need 从零实现 6 层 Encoder + 6 层 Decoder Transformer，覆盖多头注意力、位置编码、残差连接与前馈网络。
- 整理 **75,000+** 对中英文短句数据，完成 Tokenizer、平行语料清洗对齐、AdamW 与余弦退火学习率调优。
- 部署为 Hugging Face 可交互应用: huggingface.co/spaces/Huangxin14/translator_zh-en。

Resume Agent Studio: AI Agent 简历优化与模拟面试系统 个人项目

- 面向 AI 算法求职场景，搭建基于 LLM 的简历定制、岗位匹配度评估、优化建议生成与模拟面试准备工作流。
- 设计简历整理 Agent、简历评估 Agent 与面试官 Agent，使用结构化 Prompt 统一用户资料、项目经历、论文成果与岗位 JD 上下文。
- 实现 LLM JSON 输出协议与解析、修复、归一化流程，支持 DeepSeek、OpenAI-compatible API、Ollama、LM Studio 等模型来源。
- GitHub: github.com/H-X1n/Interview-master。

学术论文

SoccerStreamer: A Mamba-Augmented Streaming Framework for Causal Reasoning over Full-Match Soccer Videos AAAI 2027 在投 / CCF-A

第一作者 - 大连交通大学 & 咪咕视讯科技有限公司

- 面向足球直播流式因果视频理解任务，提出基于 Mamba 时序投影器的 VLM 框架，使模型仅依据已播出画面完成实时问答与时序推理。
- 构建严格的流式因果 QA 协议，覆盖 422 场完整比赛、12 万+ QA 模板与 3.2 万+固定 QA，并按 short/mid/long 三级记忆延迟分层。
- 通过系统消融确定最优压缩配置，在 MatchTime-Caption 任务上以约 32x token 压缩保持接近无压缩最优水平。

ARRT-DETR: Attention-Residual RT-DETR for Small-Object Detection BMVC 在投 / CCF-C

第一作者 - 大连交通大学、复旦大学、上海工程技术大学、西交利物浦大学

- 面向无人机航拍与密集交通场景小目标检测，重新设计 RT-DETR decoder 的跨层残差信息流，缓解弱定位线索在深层 refinement 中被削弱的问题。
- 提出 Attention Residual，让每层 decoder 根据当前 query 自适应检索并聚合历史 decoder 状态；设计 BARDETR 分析精度与效率权衡。
- 在 VisDrone2019 上，三层 decoder 的 ARRT-DETR 达到 47.9 mAP50 与 29.6 mAP50-95，相较 RT-DETR-L 提升 +7.2 mAP50、+5.2 mAP50-95，延迟 23.5ms。

竞赛经历

Deep Past Challenge: Translate Akkadian to English 2026.04 阿里云 Data+AI 工程师全球大奖赛 - 高校赛道 2026.02
64 / 1028 - Top 6.3%

Kaggle 银牌 - 低资源古语言机器翻译竞赛

- 完成古语言数据预处理，统一特殊符号格式并替换专有名词，降低翻译歧义。
- 微调 ByT5 与 HY-MT1.5 字符级翻译模型，并使用 MBR 解码策略进行候选译文重排序。
- 基于 PAI-LangStudio 搭建 React 模式 Research Agent，调用 Qwen3.5-Plus 完成复杂任务拆解与推理。
- 接入 Exa 与智谱联网搜索 MCP 工具，通过提示词工程与多轮评测迭代 Agent 策略。

教育经历

大连交通大学 - 交通信息工程及控制 硕士 2025.09 - 至今

研究方向：多模态流式视频内容理解；第一作者论文 SoccerStreamer 在投 AAAI 2027。

大连交通大学 - 电子信息工程 学士 2021.09 - 2025.06

专业基础：信号处理、嵌入式系统、通信原理、程序设计。